

十一、SVM

一、LR与SVM的区别

1、从损失函数（本质区别）：

SVM：对LR的一种改造，只关注离边境近的点计算损失函数（给0）

LR：对分类错的，无论远近，都有值进行损失，得到是一个概率（给一个很小的值）

2、支持向量机是有约束的，LR是无约束，约束跟支持向量紧密相关

3、LR可解释性强

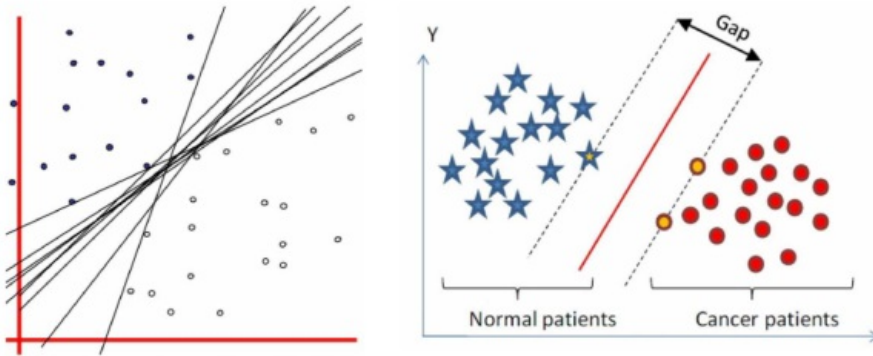
4、SVM不能给出概率结果，LR可以给出概率结果

二、SVM损失函数

SVM损失函数的就是支持向量间的最大间隔

$$\text{最大间隔分离超平面} \quad \frac{y_i \cdot y(x_i)}{\|w\|} = \frac{y_i \cdot (w^T \cdot \Phi(x_i) + b)}{\|w\|}$$

$$\square \text{ 目标函数: } \arg \max_{w, b} \left\{ \frac{1}{\|w\|} \min_i [y_i \cdot (w^T \cdot \Phi(x_i) + b)] \right\}$$



目标函数：

$$\min_{w, b} \frac{1}{2} \|w\|^2$$
$$s.t. \quad y_i (w^T \cdot \Phi(x_i) + b) \geq 1, \quad i = 1, 2, \dots, n$$

求解目标函数的问题实际上是一个凸二次规划问题（凸函数，二次）。为什么要转换为对偶问题，因为是有约束的最优化问题。求解问题，拉格朗日乘子法。

计算拉格朗日函数的对偶函数

$$\begin{aligned} w &= \sum_{i=1}^n \alpha_i y_i \Phi(x_i) \\ 0 &= \sum_{i=1}^n \alpha_i y_i \end{aligned}$$

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T \cdot \Phi(x_i) + b) - 1) \\ &= \frac{1}{2} w^T w - w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i \\ &= \frac{1}{2} w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - w^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) - b \cdot 0 + \sum_{i=1}^n \alpha_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \left(\sum_{i=1}^n \alpha_i y_i \Phi(x_i) \right)^T \sum_{i=1}^n \alpha_i y_i \Phi(x_i) \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \Phi^T(x_i) \Phi(x_j) \\ a^* &= \arg \max_{\alpha} \left(\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \Phi^T(x_i) \Phi(x_j) \right) \end{aligned}$$

整理目标函数：添加负号

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\Phi(x_i) \cdot \Phi(x_j)) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, n \end{aligned}$$

三、线性支持向量机（不可分，泛化能力强）

线性SVM的目标函数

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & y_i (w \cdot x_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, n \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, n \end{aligned}$$

□ 整理，得到对偶问题：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, n \end{aligned}$$

四、核函数

核函数其实就是相当于特征组合，高斯核把特征映射到无线维，很有可能过拟合